Diseño e Implementación de un Modelo Multidimensional (OLAP)

Etapa 5 — Análisis Multidimensional

Proyecto: Residuos Electrónicos y Consumo Tecnológico (RECT)

Jennifer Espitia, Richard Barajas y Cristian Leonardo Moscoso

Programa de Ingeniería de Sistemas y Computación, Universidad de Cundinamarca

Minería de Datos

Edison Cañón

4 de noviembre de 2026

Tema, propósito y población estudiada

El tema del proyecto es la gestión de los residuos de aparatos eléctricos y electrónicos (RAEE) y su relación con el consumo tecnológico. El propósito es entender cómo se relaciona el crecimiento del consumo tecnológico en los hogares con la capacidad de gestión formal de los residuos electrónicos, a nivel global, nacional (Colombia) y regional (Norte de Santander). Se mantiene el mismo tema, población y conjunto de datos de las etapas anteriores; no se seleccionó ningún conjunto nuevo. La población estudiada depende de la tabla de hechos: personas encuestadas sobre percepción de RAEE en Norte de Santander (fact_encuesta_ns), instalaciones de gestores autorizados de RAEE en Colombia (fact_gestores), observaciones de indicadores TIC por departamento y año (fact_dane_tic), y observaciones del % de RAEE reciclado por país/región y año (fact_reciclaje_global).

Fuente y URL original del conjunto de datos

Conjunto	Fuente	URL original
Encuesta de percepción ciudadana (Norte de Santander)	Datos Abiertos Colombia — Estudio de percepción ciudadana sobre el conocimiento de RAEE	datos.gov.co/Ciencia-Tecnolog-a-e-Innovaci-n/Estudio-de-percepci-n-ciudadana-sobre-el-conocimi/rfqz-psdm
Gestores de RAEE	Datos Abiertos Colombia — Gestores RESPEL y RAEE (IDEAM)	datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Gestores-RESPEL-y-RAEE/cxrv-qad2
Indicadores de conectividad (hogares y personas)	DANE — Encuesta Nacional de Calidad de Vida (ECV) 2024	dane.gov.co/.../encuesta-nacional-de-calidad-de-vida-ecv-2024
Tenencia de computador o tablet por departamento	DANE — ENTIC Hogares	dane.gov.co/.../encuesta-de-tecnologias-de-la-informacion-y-las-comunicaciones-en-hogares-entic-hogares
Reciclaje de RAEE por área del mundo	Our World in Data (con Eurostat WEEE e ITU DataHub como fuentes de apoyo)	ourworldindata.org/grapher/electronic-waste-recycling-rate

Los archivos tratados se encuentran en el repositorio del proyecto (datos/powerbi/ y datos/estrella/). No se seleccionó ningún conjunto de datos nuevo para esta etapa: se reutilizan las mismas fuentes ya documentadas desde la Etapa 1.

Unidad de análisis, registros y tratamiento previo

Tabla de hechos	Unidad de análisis (grano)	Registros	Tratamiento previo (Etapas 2-3)
fact_encuesta_ns	Una persona encuestada	1 917	Duplicados exactos eliminados (2 033→1 900 antes de ajustes de modelo), valores faltantes separados de respuestas negativas, canales de entrega multirrespuesta normalizados.
fact_gestores	Una instalación de gestor registrada	377 (309 activas, 68 inactivas; 327 NIT únicos)	Columna 'col' (100% nula) eliminada, fechas de texto convertidas a ISO, departamentos homologados a 33 entidades.
fact_dane_tic	Una observación de indicador TIC por dominio/año	960	109 valores porcentuales fuera de 0-100% marcados y excluidos; fuentes DANE ENTIC y ECV unificadas.
fact_reciclaje_global	Una observación de % reciclado por área/año	637	Filtrado a valores entre 0-100%, clasificación país/región/mundo homologada.

Relación con los conocimientos evidentes (Etapa 4)

La Etapa 4 identificó conocimientos evidentes —hallazgos verificables con conteos, porcentajes y comparaciones directas— sobre las mismas cuatro poblaciones, presentados en un informe estático de Power BI con cuatro tableros. La Etapa 5 no cambia de pregunta ni de datos: reorganiza esas mismas tablas en un modelo multidimensional explícito (dimensiones, jerarquías y medidas con su función de agregación) y agrega la posibilidad de navegar los resultados en distintos niveles de detalle (drill-down/roll-up) y de combinar filtros sobre dos o más dimensiones a la vez (slice/dice/pivot) de forma interactiva dentro de la propia aplicación Flask, algo que el informe estático de Power BI no permitía.

Preguntas de análisis y su justificación

Vista	Pregunta de análisis	Justificación
1. Composición	¿Cómo se distribuyen por ocupación y zona las personas encuestadas en Norte de Santander y a qué canal entregan sus residuos posconsumo?	Antes de interpretar cualquier comportamiento hay que saber a quién describe la encuesta; el canal de entrega es la variable más cercana a la gestión

Vista	Pregunta de análisis	Justificación
		formal que el proyecto busca explicar.
2. Territorial	¿Cómo se distribuyen por departamento las instalaciones de gestores autorizados de RAEE en Colombia y qué territorios quedan sin cobertura activa?	La capacidad de gestión formal es una de las dos mitades del propósito del proyecto; comparar departamentos permite ubicar la situación de Norte de Santander frente al país.
3. Temporal	¿Cómo han cambiado con el tiempo las autorizaciones otorgadas a gestores, la conectividad de los hogares y el reciclaje formal de RAEE?	El proyecto relaciona consumo tecnológico con gestión de residuos; observar sus series en el tiempo muestra si crecen al mismo ritmo.
4. Multivariado	¿Qué combinación de conocimiento del término RAEE, participación en jornadas de recolección y zona acompaña al uso del canal formal, y qué tan dispuestas están las personas a usar una app?	Permite identificar perfiles con mayor y menor uso del canal formal y orientar el diseño de la aplicación que contempla el proyecto.

Diagrama y justificación del modelo estrella

El modelo se implementa como una constelación de hechos: cuatro tablas de hechos —cada una con el grano real de su fuente, igual que en la Etapa 4— que comparten tres dimensiones conformadas (dim_departamento, dim_municipio, dim_anio). Cada tabla de hechos sigue siendo, individualmente, un esquema en estrella válido. No se creó una única tabla de hechos artificial: unir encuestados, instalaciones, indicadores TIC y observaciones de reciclaje en un solo grano habría exigido inventar una unidad de análisis que no corresponde a ninguna de las cuatro preguntas de análisis, violando la condición de la guía de no crear dimensiones (ni hechos) artificiales solo para cumplir con una forma particular.

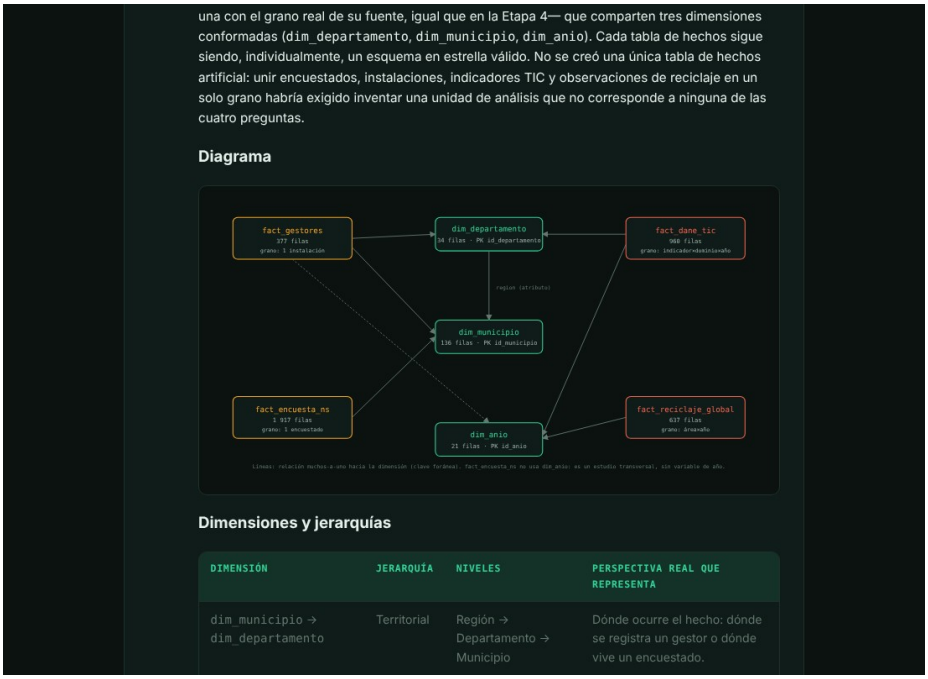


Figura 1. Diagrama de la constelación de hechos: tres dimensiones conformadas (verde) en el centro, cuatro tablas de hechos (naranja/rojo) alrededor, con sus relaciones muchos-a-uno hacia las dimensiones.

Granularidad, dimensiones, atributos, claves, medidas y jerarquías

Tablas de hechos

Tabla	Grano	Clave primaria	Claves foráneas
fact_gestores	1 instalación de gestor registrada en el IDEAM	id_registro	id_municipio → dim_municipio, id_anio → dim_anio
fact_encuesta_ns	1 persona encuestada	id_encuestado	id_municipio → dim_municipio
fact_dane_tic	1 observación de indicador TIC por dominio/año	id_dane (autoincremental)	id_departamento → dim_departamento, id_anio → dim_anio
fact_reciclaje_global	1 observación de % reciclado por área/año	id_reciclaje (autoincremental)	id_anio → dim_anio

Dimensiones y jerarquías

Dimensión	Jerarquía	Niveles	Perspectiva real que representa
dim_municipio → dim_departamento	Territorial	Región → Departamento → Municipio	Dónde ocurre el hecho: dónde se registra un gestor o dónde vive un encuestado.
dim_anio	Temporal	Década → Año	Cuándo ocurre el hecho: cuándo

Dimensión	Jerarquía	Niveles	Perspectiva real que representa
			se otorgó una autorización o se midió un indicador.

No se crearon dimensiones adicionales (p. ej. 'ocupación' o 'estado') porque esos campos son atributos descriptivos de un solo nivel dentro de su tabla de hechos, no jerarquías de agrupación válidas: se usan como ejes de la matriz y filtros de slice/dice en las vistas, no como dimensiones del modelo.

Medidas

Medida	Tabla	Unidad	Fórmula / Agregación
Instalaciones de gestores	fact_gestores	conteo	COUNT(*) — additiva: el grano es 1 fila = 1 instalación, se puede sumar en cualquier nivel.
Empresas distintas (NIT)	fact_gestores	conteo	COUNT(DISTINCT nit) — semiadditiva: un mismo NIT puede aparecer en varios municipios, se recalcula en cada consulta en vez de sumar subtotales.
Autorizaciones otorgadas	fact_gestores	conteo por año	COUNT(*) GROUP BY id_anio — additiva en el tiempo (verificado: 2000s = 55 = 6+10+12+10+17).
% hogares con internet (ECV)	fact_dane_tic	porcentaje	AVG(valor) — no additiva: ya es un porcentaje, se agrega con promedio y se recalcula al cambiar de nivel.
% RAEE reciclado	fact_reciclaje_global	porcentaje	AVG(pct_reciclado) — no additiva, misma razón que la anterior.
% que usa canal formal	fact_encuesta_ns	proporción	100 × COUNT(canal_formal='Usa canal formal') / COUNT(*) — el denominador es el conteo de encuestados del contexto de filtro activo.

Correspondencia con las variables originales: la correspondencia completa entre cada columna del modelo y su origen en datos/procesados/ (Etapa 2/3) ya está documentada en scripts/preparar_datos_pbi.py (Etapa 4); el modelo estrella reutiliza esas mismas tablas (datos/powerbi/*.csv) sin alterar ningún valor de negocio. scripts/construir_modelo_estrella.py agrega únicamente las claves subrogadas (id_departamento, id_municipio, id_anio) y la jerarquía temporal (decada), y deja la fila

sentinela id_departamento = 0 para los 69 registros de fact_dane_tic que son agregados nacionales sin departamento.

Herramientas seleccionadas y justificación

Herramienta	Uso	Justificación
SQLite	Almacenamiento del modelo estrella (datos/estrella/rect_estrella.db)	Motor relacional real con PK/FK explícitas y PRAGMA foreign_keys=ON; un solo archivo que cabe en el repositorio; se consulta con SQL estándar directamente desde Flask (módulo sqlite3 de la librería estándar), sin dependencias adicionales de servidor.
Python / pandas	Carga reproducible (ETL) y verificación del modelo	Mismo lenguaje y librería ya usados en las Etapas 2-4 del proyecto; permite comparar los conteos del modelo contra los CSV tratados en el mismo script.
Flask	Cuatro vistas interactivas y capa de consultas OLAP (rect_olap.py)	Framework ya usado por toda la aplicación del proyecto; las operaciones multidimensionales se implementan como funciones Python que arman SQL parametrizado según los filtros de la URL (querystring).
Chart.js	Visualizaciones (barras, dona, línea) en las 4 vistas	Ya usado en las Etapas 2 y 4 de la aplicación; se sirve localmente (static/js/vendor/) en vez de desde un CDN externo, para que las vistas funcionen igual sin conexión a internet.

Procedimiento de transformación y carga

La carga del modelo es reproducible con un único comando: python scripts/construir_modelo_estrella.py. El script (1) crea el esquema desde scripts/esquema_estrella.sql, (2) carga dim_departamento añadiendo una fila sentinela (id=0) para los agregados nacionales, (3) carga dim_anio calculando la columna decada, (4) construye dim_municipio a partir de los municipios distintos de fact_gestores y fact_encuesta_ns, resolviendo su departamento, y (5) carga las cuatro tablas de hechos resolviendo sus claves foráneas contra las dimensiones ya cargadas. El script recrea el archivo .db completo desde cero en cada ejecución (no es una carga incremental), lo que garantiza que el modelo siempre reflique exactamente el contenido actual de datos/powerbi/.

Validaciones del modelo y comparación con los datos de origen

scripts/verificar_modelo_estrella.py ejecuta 25 comprobaciones automáticas sobre el modelo cargado, agrupadas en 5 categorías, y las 25 pasaron sin falla en la última ejecución:

Categoría	Comprobaciones	Resultado
1. Unicidad de claves de dimensión	dim_departamento, dim_municipio y dim_anio: la clave primaria no tiene valores repetidos.	3/3 OK
2. Correspondencia de claves foráneas	Ninguna fila de las 4 tablas de hechos referencia una clave que no exista en su dimensión (sin filas huérfanas).	6/6 OK
3. Ausencia de duplicaciones indebidas	Clave primaria única en cada tabla de hechos; eventos de registro de gestores (NIT+establecimiento+municipio+fecha) sin repetirse; renovaciones del mismo NIT (problema P03, Etapa 2) se conservan como instalaciones separadas, no se cuentan como error.	6/6 OK
4. Tratamiento de valores faltantes	Ningún encuestado ni instalación quedó sin municipio resuelto; los 69 agregados nacionales de fact_dane_tic quedan marcados con id_departamento=0 (no se pierden ni se dejan nulos); 'Sin dato' de Vigencia se conserva como categoría explícita.	4/4 OK
5. Coherencia de conteos y agregaciones	Mismo número de filas en el modelo que en cada CSV tratado de origen (4 tablas); el top 5 de departamentos con gestores activos coincide con el CSV (184 = 184); la suma de instalaciones ACTIVO + INACTIVO es igual al total (no se multiplican filas al unir con las dimensiones).	6/6 OK

Consultas y evidencias de las operaciones multidimensionales

Drill-down / Roll-up — Vista 2, Territorial

Cambia el nivel de la jerarquía Región → Departamento → Municipio (parámetro nivel en rect_olap.cubo_territorial) y recalcula COUNT(*) agrupando por la columna correspondiente en cada nivel, no solo el tipo de gráfica.

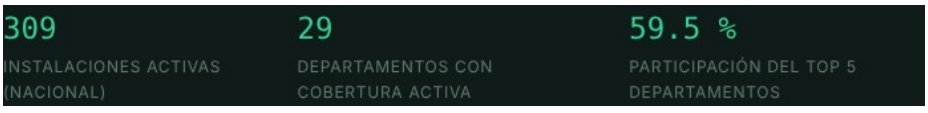


Figura 2. Indicadores de la Vista 2 (Territorial) a nivel departamento, estado = Activo: 309 instalaciones, 29 departamentos con cobertura activa, 59.5% de participación del top 5.



Figura 3. Control de nivel (región/departamento/municipio) y filtros de región, departamento y estado de la Vista 2.

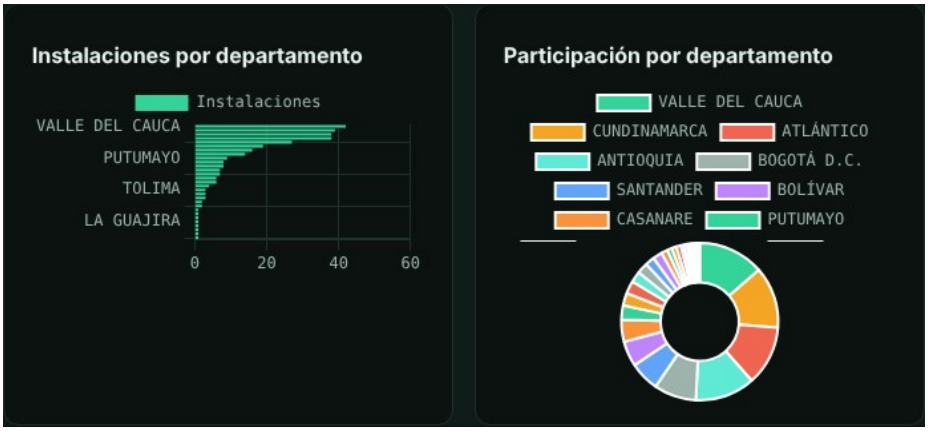


Figura 4. Instalaciones por departamento (roll-up al nivel por defecto): barras y dona, calculadas con COUNT(*) GROUP BY departamento.

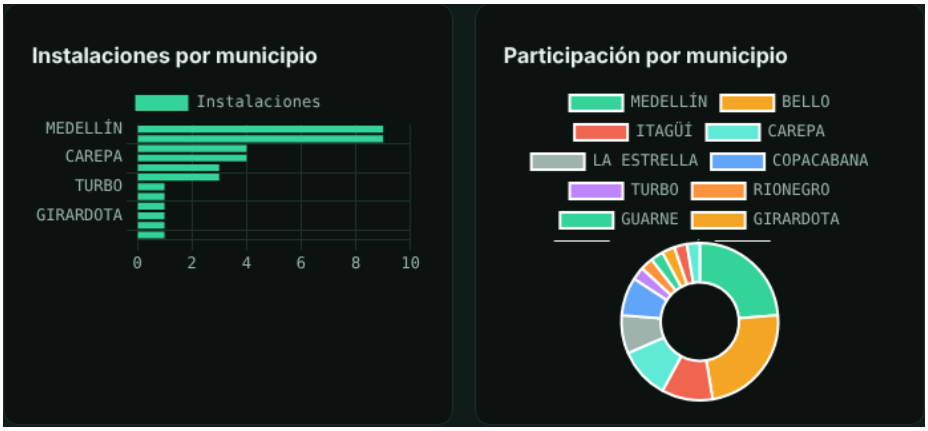


Figura 5. Mismo indicador tras hacer drill-down a nivel municipio, filtrado a Antioquia: la medida se recalcula agrupando por municipio en vez de por departamento.

Slice — Vista 1, Composición

Fija el valor de una dimensión (zona, o si tiene residuos en casa) y recalcula la matriz y los indicadores solo sobre ese subconjunto, sin alterar la consulta de las demás dimensiones.

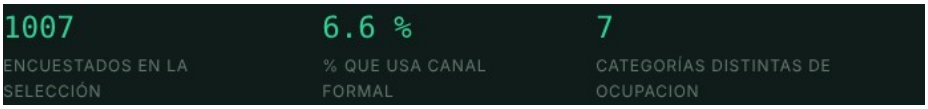


Figura 6. Indicadores de la Vista 1 con el slice por defecto (sin RAEE en casa, todas las zonas): 1 007 encuestados en la selección, 6.6% usa canal formal.

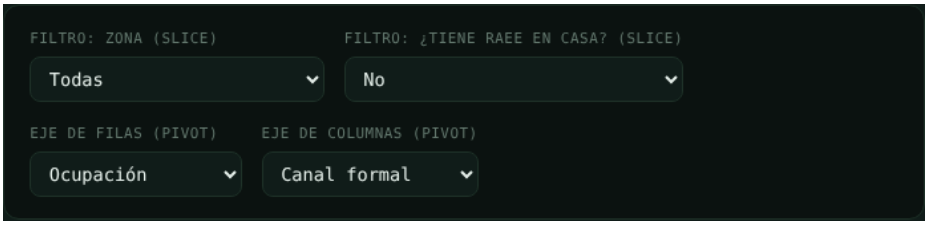


Figura 7. Filtros de slice (zona, tiene RAEE en casa) y controles de pivot (eje de filas / eje de columnas) de la Vista 1.

Dice — Vista 4, Multivariado

Fija valores simultáneos en dos o tres dimensiones distintas (sabe_raee, participo_jornada, zona) a la vez, lo que aísla un subconjunto más específico que un slice sobre una sola dimensión.



Figura 8. Tres filtros simultáneos (¿sabe qué es RAEE?, ¿participó en jornada?, zona) sobre tres dimensiones distintas de la Vista 4: ejemplo real de dice.

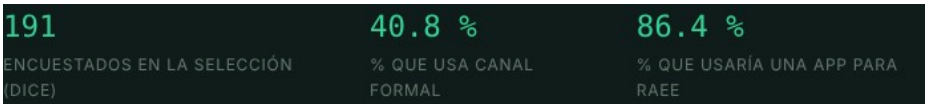


Figura 9. Con el dice sabe_raee=Sí, participo_jornada=Sí, zona=Cúcuta aplicado: el % que usa canal formal sube de 17.6% (población general) a 40.8% en este subconjunto.

Pivot — Vista 1 y Vista 4

Intercambia qué campo va en filas y cuál en columnas de la misma consulta agregada (parámetros fila/columna de rect_olap.cubo_composicion y rect_olap.cubo_multivariado); el resultado se reordena, no se recalcula desde cero con otra lógica.

CANAL_FORMAL \ OCUPACION	AMA DE CASA	DESEMPLEADO	EMPLEADO SECTOR PRIVADO	EMPLEADO
No usa canal formal	32	74	81	
Usa canal formal	—	3	3	

Figura 10. Matriz de la Vista 1 con fila=canal_formal y columna=ocupación (ejes intercambiados respecto a la Figura 11), filtrada a zona=Cúcuta.

CANAL_FORMAL \ USARIA_APP_RAEE	NO	NO: BARRERA TECNOLÓGICA	NO: NO LE INTERESA	SÍ
No usa canal formal	13	1	2	97
Usa canal formal	8	2	—	68

Figura 11. Matriz de la Vista 4 (fila=canal_formal, columna=usaría_app_raee) sobre el subconjunto filtrado por dice de la Figura 9.

Evidencias de las cuatro vistas

Cada una de las 4 vistas presenta 3 indicadores, 2 visualizaciones, 1 matriz, 2 filtros interactivos y los controles de operación multidimensional correspondientes a su pregunta, además de la interpretación, 2 conocimientos documentados, 1 limitación y 1 decisión sustentada. Las Figuras 2 a 11 ya muestran la evidencia de indicadores, controles, visualizaciones y matrices de las Vistas 1, 2 y 4; la Vista 3 se documenta a continuación.



Figura 12. Indicadores de la Vista 3 (Temporal), fuente = autorizaciones a gestores: 361 autorizaciones otorgadas en total (2005-2025).

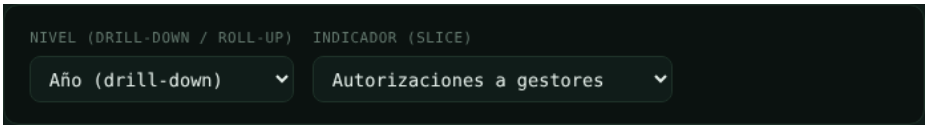


Figura 13. Control de nivel (década/año) y de fuente del indicador (slice) de la Vista 3.

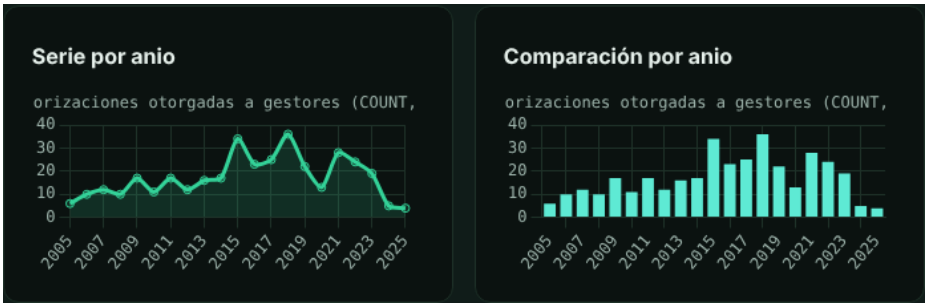


Figura 14. Autorizaciones otorgadas por año (drill-down al nivel más detallado), línea y barras.

DÉCADA	AUTORIZACIONES (COUNT)	% INTERNET, ECV (AVG)	% RECICLADO MUNDIAL (AVG)
2000s	55	—	—
2010s	213	52.1	22.7
2020s	93	61.2	22.7

Figura 15. Matriz de la Vista 3 cruzando década con los tres indicadores (autorizaciones, % internet ECV, % reciclado mundial), cada uno con su propia unidad y función de agregación.

Los 8 conocimientos multidimensionales

#	Vista	Conocimiento	Hallazgo (con cifra verificable)
1	Territorial	Concentración territorial en el top 5	5 de 29 departamentos con cobertura activa (17%) concentran 184 de 309 instalaciones activas (59.5%).
2	Territorial	Territorios sin cobertura activa	29 de 33 departamentos tienen al menos una instalación activa; 4 (Arauca, Guainía, Vaupés, Vichada) no tienen ninguna.
3	Temporal	Autorizaciones crecen y luego se desaceleran	Autorizaciones por década: 55 (2000s) → 213 (2010s) → 93 (2020s, incompleta).
4	Temporal	Conectividad crece, reciclaje formal se estanca	% hogares con internet: 52.1% (2010s) → 61.22% (2020s). % RAEE reciclado mundial: 22.73% → 22.69% (prácticamente estancado).
5	Composición	El canal formal es minoritario en todas las ocupaciones	En ninguna categoría de ocupación el canal formal supera a la entrega informal; 6.6% de uso formal en la selección por defecto.
6	Composición	La zona cambia la composición, no solo el tamaño de muestra	Cúcuta aporta 66.3% de los encuestados de la selección (668/1 007); la composición por ocupación dentro de Cúcuta difiere de la muestra completa.
7	Multivariado	Conocer RAEE y haber participado se asocia a mayor uso formal	% canal formal sube de 17.6% (población general) a 40.8% en el subconjunto que conoce RAEE, participó antes y vive en Cúcuta.
8	Multivariado	La disposición a usar una app no depende del comportamiento actual	86.4% de los encuestados del subconjunto filtrado usaría una app para RAEE, casi igual entre quienes ya usan y no usan el canal formal.

Cada uno de los 8 conocimientos está documentado en su vista correspondiente de la aplicación Flask (/etapa-5/composicion, /territorial, /temporal, /multivariado) con los 8 elementos solicitados: pregunta, dimensiones y medidas, procedimiento, evidencia, hallazgo, interpretación, utilidad y limitación.

Limitaciones y decisiones sustentadas

Vista	Limitación	Decisión sustentada en los datos
Territorial	El registro del IDEAM puede no contener instalaciones que dejaron de operar antes del corte de descarga; el número de inactivas podría estar subestimado.	Priorizar campañas de registro formal de gestores en los 4 departamentos sin cobertura activa (Conocimiento 2), antes que reforzar el top 5 que ya concentra el 59.5%.
Temporal	Las tres series cubren periodos distintos (2005-2025, 2018-2024, 2010-2022); no son comparables año a año, por eso se agrupan por década.	Usar la década como unidad de seguimiento del avance del proyecto, no el año individual, para amortiguar el ruido y comparar series con distinta cobertura temporal.
Composición	La encuesta tiene 991 valores distintos de entidad y casos repetidos de una misma institución (problema ya señalado en la Etapa 4): posible sesgo de selección.	Diseñar cualquier campaña de canal formal como intervención departamental amplia (Conocimiento 5), no solo urbana (Conocimiento 6).
Multivariado	Al combinar 3 filtros (dice) el tamaño de la submuestra baja rápido; los porcentajes sobre subconjuntos pequeños tienen más variabilidad.	Incluir en la hoja de ruta del proyecto el desarrollo de un canal digital (app), apoyado en el Conocimiento 8: la intención de uso no está limitada a quienes ya participan del canal formal.

Conclusiones

El modelo multidimensional confirma, con capacidad de explorar distintos niveles de detalle, el diagnóstico que venía tomando forma desde la Etapa 4: el consumo tecnológico (conectividad, tenencia de dispositivos) crece de forma sostenida y más rápido que la capacidad formal de gestión de los residuos que ese mismo consumo genera, tanto en el tiempo (Conocimientos 3 y 4) como en el territorio (Conocimientos 1 y 2). A nivel de comportamiento ciudadano, la brecha no parece ser solo de infraestructura: incluso entre quienes conocen el término RAEE y ya han participado en una jornada, el canal formal sigue sin ser mayoritario (Conocimientos 5 y 7), mientras que la disposición a adoptar un canal digital es amplia y no depende del comportamiento actual (Conocimiento 8). Esto sustenta una recomendación concreta para las siguientes etapas del proyecto: explorar un canal digital como puente entre la intención declarada y el comportamiento formal real, dirigido a toda la población encuestada y no solo a quienes ya participan.

Evidencias del trabajo en el repositorio

Los archivos de esta etapa se incorporaron al repositorio del proyecto en la rama feature/etapa-5: scripts/esquema_estrella.sql, scripts/construir_modelo_estrella.py, scripts/verificar_modelo_estrella.py (25 comprobaciones), rect_olap.py (consultas OLAP), datos/estrella/rect_estrella.db (modelo cargado), datos/estrella/README.md (diccionario del modelo), templates/etapa5/ (7 plantillas), static/js/vendor/chart.umd.js, y los cambios correspondientes en app.py y static/css/style.css para integrar la nueva sección 'Análisis multidimensional' al menú de la aplicación.



Figura 16. Nueva tarjeta R5 integrada en el menú principal de la aplicación Flask, junto a las entregas R1-R4 ya publicadas.

Enlaces del proyecto

Repositorio público en GitHub: https://github.com/Jennespi/RECT

Rama de esta entrega (feature/etapa-5):

https://github.com/Jennespi/RECT/tree/feature/etapa-5

Aplicación publicada: https://rect-tfdr.onrender.com

Referencias

Datos Abiertos Colombia. (s.f.). Estudio de percepción ciudadana sobre el conocimiento de RAEE. https://www.datos.gov.co/Ciencia-Tecnolog-a-e-Innovaci-n/Estudio-de-percepci-n-ciudadana-sobre-el-conocimie/rfqz-psdm

Datos Abiertos Colombia. (s.f.). Gestores RESPEL y RAEE. https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Gestores-RESPEL-y-RAEE/cxrv-qad2

Departamento Administrativo Nacional de Estadística (DANE). (2024). Encuesta Nacional de Calidad de Vida (ECV). https://www.dane.gov.co/index.php/estadisticas-por-tema/salud/calidad-de-vida-ecv/encuesta-nacional-de-calidad-de-vida-ecv-2024

Departamento Administrativo Nacional de Estadística (DANE). (s.f.). Encuesta de Tecnologías de la Información y las Comunicaciones en Hogares (ENTIC Hogares). https://www.dane.gov.co/index.php/estadisticas-por-tema/tecnologia-e-innovacion/tecnologias-de-la-informacion-y-las-comunicaciones-tic/encuesta-de-tecnologias-de-la-informacion-y-las-comunicaciones-en-hogares-entic-hogares

Our World in Data. (s.f.). Electronic waste recycling rate. https://ourworldindata.org/grapher/electronic-waste-recycling-rate

Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3rd ed.). Wiley.